Московский государственный технический университет им. Н.Э. Баумана
Факультет «Информатика и системы управления»
Кафедра «Автоматизированные системы обработки информации и управления»

Отчет

Лабораторная работа № 5

По курсу «Технологии машинного обучения»

«Линейные модели, SVM и деревья решений»

ИСПОЛНИТЕЛЬ:

Харчевников А.А. Группа ИУ5-64

_____

"__"_____2020 г.

ПРЕПОДАВАТЕЛЬ:

Гапанюк Ю.Е.

_____

"__"_____2020 г.

Москва 2020

1. Цель лабораторной работы

Изучение линейных моделей, SVM и деревьев решений

2. Задание

1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
4. Обучите следующие модели:
    - одну из линейных моделей;
    - SVM;
    - дерево решений.
5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

3. Дополнительное задание

1. Проведите эксперименты с важностью признаков в дереве решений;
2. Визуализируйте дерево решений.

4. Ход выполнения лабораторной работы

Подключим необходимые библиотеки и загрузим датасет

[1]:
```
import pandas as pd
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.linear_model import SGDClassifier
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import f1_score, precision_score
from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier, plot_tree

%matplotlib inline

# Устанавливаем тип графиков
sns.set(style="ticks")

# Для лучшего качестваа графиков
from IPython.display import set_matplotlib_formats
set_matplotlib_formats("retina")
```

```
# Устанавливаем ширину экрана для отчета
pd.set_option("display.width", 70)


# Загружаем данные
data = pd.read_csv('heart.csv')
data.head()
```

[1]:
```
   age  sex  cp  trestbps  chol  fbs  restecg  thalach  exang  \
0   63    1   3       145   233    1        0      150      0
1   37    1   2       130   250    0        1      187      0
2   41    0   1       130   204    0        0      172      0
3   56    1   1       120   236    0        1      178      0
4   57    0   0       120   354    0        1      163      1

   oldpeak  slope  ca  thal  target
0      2.3      0   0     1       1
1      3.5      0   0     2       1
2      1.4      2   0     2       1
3      0.8      2   0     2       1
4      0.6      2   0     2       1
```

[2]:
```
data.isnull().sum()
```

[2]:
```
age         0
sex         0
cp          0
trestbps    0
chol        0
fbs         0
restecg     0
thalach     0
exang       0
oldpeak     0
slope       0
ca          0
thal        0
target      0
dtype: int64
```

[3]:
```
data.isna().sum()
```

[3]:
```
age         0
sex         0
cp          0
trestbps    0
chol        0
fbs         0
restecg     0
thalach     0
exang       0
```

```
oldpeak     0
slope       0
ca          0
thal        0
target      0
dtype: int64
```

Как видим, пустых значений нет, значет нет необходимости преобразовывать набор данных

[4]:
```
# Разделим данные на целевой столбец и признаки
X = data.drop("target", axis=1)
y = data["target"]
print(X, "\n")
print(y)
```

```
      age  sex  cp  trestbps  chol  fbs  restecg  thalach  exang  \
0      63    1   3       145   233    1        0      150      0
1      37    1   2       130   250    0        1      187      0
2      41    0   1       130   204    0        0      172      0
3      56    1   1       120   236    0        1      178      0
4      57    0   0       120   354    0        1      163      1
..    ...  ...  ..       ...   ...  ...      ...      ...    ...
298    57    0   0       140   241    0        1      123      1
299    45    1   3       110   264    0        1      132      0
300    68    1   0       144   193    1        1      141      0
301    57    1   0       130   131    0        1      115      1
302    57    0   1       130   236    0        0      174      0

      oldpeak  slope  ca  thal
0         2.3      0   0     1
1         3.5      0   0     2
2         1.4      2   0     2
3         0.8      2   0     2
4         0.6      2   0     2
..        ...    ...  ..   ...
298       0.2      1   0     3
299       1.2      1   0     3
300       3.4      1   2     3
301       1.2      1   1     3
302       0.0      1   1     2

[303 rows x 13 columns]

0      1
1      1
2      1
3      1
4      1
      ..
298    0
```

```
299    0
300    0
301    0
302    0
Name: target, Length: 303, dtype: int64
```

[5]:
```
# Предобработаем данные, чтобы методы работали лучше
columns = X.columns
scaler = StandardScaler()
X = scaler.fit_transform(X)
pd.DataFrame(X, columns=columns).describe()
```

[5]:

	age	sex	cp	trestbps	\
count	3.030000e+02	3.030000e+02	3.030000e+02	3.030000e+02	
mean	4.690051e-17	-1.407015e-16	2.345026e-17	-7.035077e-16	
std	1.001654e+00	1.001654e+00	1.001654e+00	1.001654e+00	
min	-2.797624e+00	-1.468418e+00	-9.385146e-01	-2.148802e+00	
25%	-7.572802e-01	-1.468418e+00	-9.385146e-01	-6.638668e-01	
50%	6.988599e-02	6.810052e-01	3.203122e-02	-9.273778e-02	
75%	7.316189e-01	6.810052e-01	1.002577e+00	4.783913e-01	
max	2.496240e+00	6.810052e-01	1.973123e+00	3.905165e+00	

	chol	fbs	restecg	thalach	\
count	3.030000e+02	3.030000e+02	3.030000e+02	3.030000e+02	
mean	-1.113887e-16	-2.345026e-17	1.465641e-16	-6.800574e-16	
std	1.001654e+00	1.001654e+00	1.001654e+00	1.001654e+00	
min	-2.324160e+00	-4.176345e-01	-1.005832e+00	-3.439267e+00	
25%	-6.814943e-01	-4.176345e-01	-1.005832e+00	-7.061105e-01	
50%	-1.210553e-01	-4.176345e-01	8.989622e-01	1.466343e-01	
75%	5.456738e-01	-4.176345e-01	8.989622e-01	7.151309e-01	
max	6.140401e+00	2.394438e+00	2.803756e+00	2.289429e+00	

	exang	oldpeak	slope	ca	\
count	3.030000e+02	3.030000e+02	3.030000e+02	3.030000e+02	
mean	-4.690051e-17	2.345026e-17	-1.407015e-16	-2.345026e-17	
std	1.001654e+00	1.001654e+00	1.001654e+00	1.001654e+00	
min	-6.966305e-01	-8.968617e-01	-2.274579e+00	-7.144289e-01	
25%	-6.966305e-01	-8.968617e-01	-6.491132e-01	-7.144289e-01	
50%	-6.966305e-01	-2.067053e-01	-6.491132e-01	-7.144289e-01	
75%	1.435481e+00	4.834512e-01	9.763521e-01	2.650822e-01	
max	1.435481e+00	4.451851e+00	9.763521e-01	3.203615e+00	

	thal
count	3.030000e+02
mean	-1.641518e-16
std	1.001654e+00
min	-3.784824e+00
25%	-5.129219e-01
50%	-5.129219e-01
75%	1.123029e+00

max 1.123029e+00

[6]:
```
# С использованием метода train_test_split разделим выборку на обучающую и тестовую
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=1)
print("X_train:", X_train.shape)
print("X_test:", X_test.shape)
print("y_train:", y_train.shape)
print("y_test:", y_test.shape)
```

X_train: (227, 13)
X_test: (76, 13)
y_train: (227,)
y_test: (76,)

[7]:
```
def test_model(model):
    print("f1_score:",
          f1_score(y_test, model.predict(X_test)))
    print("precision_score:",
          precision_score(y_test, model.predict(X_test)))
```

Линейная модель — SGDClassifier

[8]:
```
SGD = SGDClassifier(max_iter=10000)
SGD.fit(X_train, y_train)
```

[8]:
```
SGDClassifier(alpha=0.0001, average=False, class_weight=None,
              early_stopping=False, epsilon=0.1, eta0=0.0, fit_intercept=True,
              l1_ratio=0.15, learning_rate='optimal', loss='hinge',
              max_iter=10000, n_iter_no_change=5, n_jobs=None, penalty='l2',
              power_t=0.5, random_state=None, shuffle=True, tol=0.001,
              validation_fraction=0.1, verbose=0, warm_start=False)
```

[9]:
```
test_model(SGD)
```

f1_score: 0.7804878048780488
precision_score: 0.7804878048780488

SVM

[10]:
```
SVC = SVC(kernel='rbf')
SVC.fit(X_train, y_train)
```

[10]:
```
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='scale', kernel='rbf',
    max_iter=-1, probability=False, random_state=None, shrinking=True,
```

```
tol=0.001, verbose=False)
```

[11]:
```
test_model(SVC)
```

```
f1_score: 0.8275862068965518
precision_score: 0.782608695652174
```

Дерево решений

[12]:
```
DT = DecisionTreeClassifier(random_state=1)
DT.fit(X_train, y_train)
```

[12]:
```
DecisionTreeClassifier(ccp_alpha=0.0, class_weight=None, criterion='gini',
                       max_depth=None, max_features=None,␣
↪max_leaf_nodes=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, presort='deprecated',
                       random_state=1, splitter='best')
```

[13]:
```
test_model(DT)
```

```
f1_score: 0.72
precision_score: 0.7941176470588235
```

[14]:
```
fig, ax = plt.subplots(figsize=(50, 50))
plot_tree(DT, ax=ax, filled='true', fontsize=12, feature_names=data.
↪columns)
plt.savefig('tree_high_dpi', dpi=100)
```

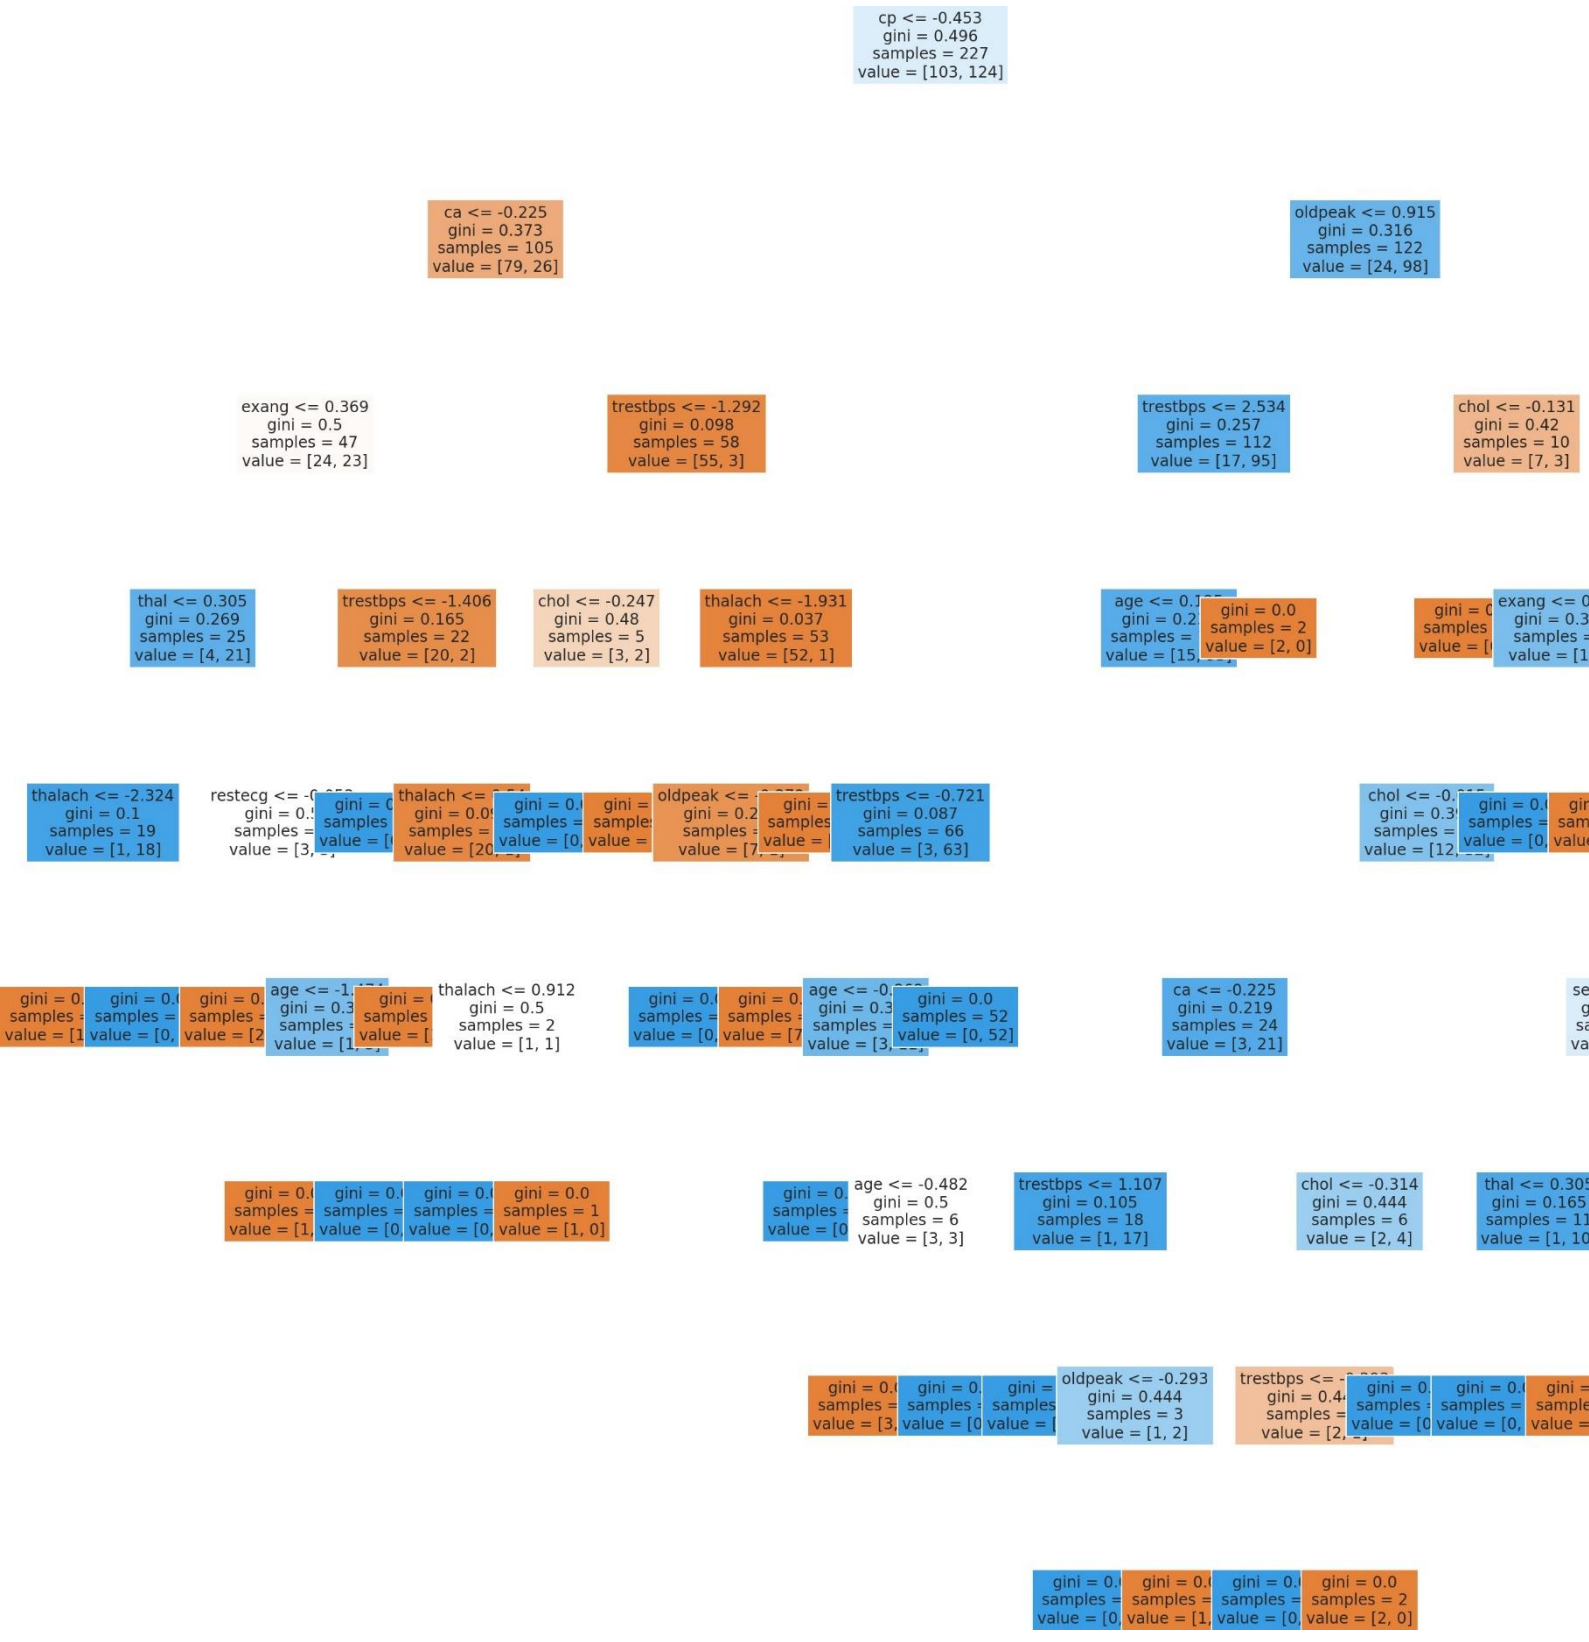
cp <= -0.453
gini = 0.496
samples = 227
value = [103, 124]
ca <= -0.225
gini = 0.373
samples = 105
value = [79, 26]
oldpeak <= 0.915
gini = 0.316
samples = 122
value = [24, 98]
exang <= 0.369
gini = 0.5
samples = 47
value = [24, 23]
trestbps <= -1.292
gini = 0.098
samples = 58
value = [55, 3]
trestbps <= 2.534
gini = 0.257
samples = 112
value = [17, 95]
chol <= -0.131
gini = 0.42
samples = 10
value = [7, 3]
thal <= 0.305
gini = 0.269
samples = 25
value = [4, 21]
trestbps <= -1.406
gini = 0.165
samples = 22
value = [20, 2]
chol <= -0.247
gini = 0.48
samples = 5
value = [3, 2]
thalach <= -1.931
gini = 0.037
samples = 53
value = [52, 1]
gini = 0.0
samples = 2
value = [2, 0]
thalach <= -2.324
gini = 0.1
samples = 19
value = [1, 18]
trestbps <= -0.721
gini = 0.087
samples = 66
value = [3, 63]
thalach <= 0.912
gini = 0.5
samples = 2
value = [1, 1]
gini = 0.0
samples = 52
value = [0, 52]
ca <= -0.225
gini = 0.219
samples = 24
value = [3, 21]
gini = 0.0
samples = 1
value = [1, 0]
age <= -0.482
gini = 0.5
samples = 6
value = [3, 3]
trestbps <= 1.107
gini = 0.105
samples = 18
value = [1, 17]
chol <= -0.314
gini = 0.444
samples = 6
value = [2, 4]
oldpeak <= -0.293
gini = 0.444
samples = 3
value = [1, 2]
gini = 0.0
samples = 2
value = [2, 0]

Как видим, метод опорных векторов показал лучший результат.