# Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления»

Кафедра «Автоматизированные системы обработки информации и управления»



# Отчет Лабораторная работа № 3

# По курсу «Технологии машинного обучения»

# «Изучение библиотек обработки данных»

ИСПОЛНИТЕЛЬ:
Харчевников А.А. Группа ИУ5-64
""2020 г.
ПРЕПОДАВАТЕЛЬ:
Гапанюк Ю.Е.
""2020 г.

# 1. Цель работы

Изучение библиотеки обработки данных Pandas.

#### 2. Описание задания

- Выполнить первое демонстрационное задание "demo assignment" под названием "Exploratory data analysis with Pandas" со страницы курса <a href="https://mlcourse.ai/assignments">https://mlcourse.ai/assignments</a>.
- Сформировать отчет и разместить его на своем репозитории GitHub

## 3. Выполнение задания

Подключим выбранный набор данных

# 1. Загрузка и первичный анализ:

```
In [16]: import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
In [17]: data = pd.read_csv('../data/vgsales.csv', sep=",", engine="python")
```

```
In [18]: # Список колонок с типами данных
           data.dtypes
  Out[18]: Rank
            Name
                            object
                      object
float64
object
            Platform
           Year
Genre
           Publisher
                            object
           NA_Sales
EU_Sales
                           float64
            JP_Sales
                           float64
           Other_Sales
Global_Sales
                            float64
                           float64
           dtype: object
  In [19]: # Проверка на пропуски data.isnull().sum()
  Out[19]: Rank
           Platform
            Year
            Genre
           Publisher
                            58
            NA_Sales
           EU_Sales
JP Sales
                             0
           Other_Sales
Global Sales
            dtype: int64
  In [20]: # Размер датасета
           data.shape
  Out[20]: (16598, 11)
  In [21]: data.head()
  Out[21]:
              Rank
                                   Name Platform Year
                                                            Genre Publisher NA_Sales EU_Sales JP_Sales Other_Sales Global_Sales
           0 1 Wii Sports Wii 2006.0 Sports Nintendo 41.49 29.02 3.77 8.46
                                                                                                                      82.74
                     Super Mario Bros. NES 1985.0 Platform Nintendo
                                                                              29.08
                                                                                        3.58
                                                                                                6.81
                                                                                                            0.77
                                                                                                                       40.24
            1 2
           2
                3
                         Mario Kart Wii Wii 2008.0
                                                           Racing Nintendo
                                                                              15.85
                                                                                        12.88
                                                                                                3.79
                                                                                                           3.31
                                                                                                                      35.82
                4
                                             Wii 2009.0
                                                                               15.75
                                                                                        11.01
                                                                                                 3.28
                                                                                                            2.96
                                                                                                                       33.00
           4 5 Pokemon Red/Pokemon Blue GB 1996.0 Role-Playing Nintendo
                                                                              11.27
                                                                                        8.89
                                                                                                10.22
                                                                                                            1.00
                                                                                                                       31.37
In [103]: total_count = data.shape[0]
print('Bcero cτροκ: {}'.format(total_count))
          Всего строк: 16598
```

# 2. Обработка пропусков

## 2.1. Простая стратегия – удаление или заполнение нулями

#### Обработка пропусков в данных

#### Простые стратегии - удаление или заполнение нулями

```
In [104]: # Удаление колонок, содержащих пустые значения data_new_1 = data.dropna(axis=1, how='any') (data.shape, data_new_1.shape)

Out[104]: ((16598, 11), (16598, 9))

In [105]: # Удаление строк, содержащих пустые значения data_new_2 = data.dropna(axis=0, how='any') (data.shape, data_new_2.shape)

Out[105]: ((16598, 11), (16291, 11))
```



#### 2.2. Импьютация

#### 2.2.1. Обработка пропусков в числовых данных

"Внедрение значений" - импьютация (imputation)

Обработка пропусков в числовых данных

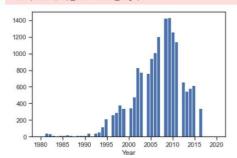
```
In [108]: # Выберем числовые колонки с пропущенными значениями
             # Цикл по колонкам датасета
            num_cols = []
for col in data.columns:
                 # Количество пустых значений
temp_null_count = data[data[col].isnull()].shape[0]
                      str(data[col].dtype)
                 if temp_null_count>0 and (dt=='float64' or dt=='int64'):
    num_cols.append(col)
                     Temp_perc = round((temp_null_count / total_count) * 100.0, 2)
print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
            Колонка Year. Тип данных float64. Количество пустых значений 271, 1.63%.
In [109]: # Фильтр по колонкам с пропущенными значениями
            data_num = data[num_cols]
            data_num
Out[109]:
                     Year
            0 2006.0
            2 2008.0
                3 2009 0
            4 1996.0
             16593 2002.0
             16594 2003 0
             16595 2008.0
             16597 2003.0
            16598 rows × 1 columns
```

```
In [110]: # Fucmozpamma no npushakam

for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()

c:\users\administrator\pycharmprojects\rk_tmm\venv\lib\site-packages\numpy\lib\histograms.py:839: RuntimeWarning: invalid value encountered in greater_equal
    keep = (tmp_a >= first_edge)

c:\users\administrator\pycharmprojects\rk_tmm\venv\lib\site-packages\numpy\lib\histograms.py:840: RuntimeWarning: invalid value encountered in less_equal
    keep &= (tmp_a <= last_edge)
```



In [111]: # Фильтр по пустым значениям поля Year data[data['Year'].isnull()]

	111	
UUL	111	
CALIFORNIA CONTRACTOR		

	Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sales	JP_Sales	Other_Sales	Global_Sales
179	180	Madden NFL 2004	PS2	NaN	Sports	Electronic Arts	4.26	0.26	0.01	0.71	5.23
377	378	FIFA Soccer 2004	PS2	NaN	Sports	Electronic Arts	0.59	2.36	0.04	0.51	3.49
431	432	LEGO Batman: The Videogame	Wii	NaN	Action	Warner Bros. Interactive Entertainment	1.86	1.02	0.00	0.29	3.17
470	471	wwe Smackdown vs. Raw 2006	PS2	NaN	Fighting	NaN	1.57	1.02	0.00	0.41	3.00
607	608	Space Invaders	2600	NaN	Shooter	Atari	2.36	0.14	0.00	0.03	2.53
		300	(1000)		222		(888	***	***	***	(444)
16307	16310	Freaky Flyers	GC	NaN	Racing	Unknown	0.01	0.00	0.00	0.00	0.01
16327	16330	Inversion	PC	NaN	Shooter	Namco Bandai Games	0.01	0.00	0.00	0.00	0.01
16366	16369	Hakuouki: Shinsengumi Kitan	PS3	NaN	Adventure	Unknown	0.01	0.00	0.00	0.00	0.01
16427	16430	Virtua Quest	GC	NaN	Role- Playing	Unknown	0.01	0.00	0.00	0.00	0.01
16493	16496	The Smurfs	3DS	NaN	Action	Unknown	0.00	0.01	0.00	0.00	0.01

271 rows × 11 columns

In [112]: # Запоминаем индексы строк с пустыми значениями flt\_index = data[data['Year'].isnull()].index flt\_index

```
Out[112]: Int64Index([ 179, 377, 431, 470, 607, 624, 649, 652, 711, 782, ...
16191, 16194, 16198, 16229, 16246, 16307, 16327, 16366, 16427, 16493],
dtype='int64', length=271)
```

In [113]: # Проверяем что выводятся нужные строки data[data.index.isin(flt\_index)]

#### Out[113]:

	Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sales	JP_Sales	Other_Sales	Global_Sales
179	180	Madden NFL 2004	PS2	NaN	Sports	Electronic Arts	4.26	0.26	0.01	0.71	5.23
377	378	FIFA Soccer 2004	PS2	NaN	Sports	Electronic Arts	0.59	2.36	0.04	0.51	3.49
431	432	LEGO Batman: The Videogame	Wii	NaN	Action	Warner Bros. Interactive Entertainment	1.86	1.02	0.00	0.29	3.17
470	471	wwe Smackdown vs. Raw 2006	PS2	NaN	Fighting	NaN	1.57	1.02	0.00	0.41	3.00
607	608	Space Invaders	2600	NaN	Shooter	Atari	2.36	0.14	0.00	0.03	2.53
•••	111		***	***	100	3404	***		300	500	***
16307	16310	Freaky Flyers	GC	NaN	Racing	Unknown	0.01	0.00	0.00	0.00	0.01
16327	16330	Inversion	PC	NaN	Shooter	Namco Bandai Games	0.01	0.00	0.00	0.00	0.01
16366	16369	Hakuouki: Shinsengumi Kitan	PS3	NaN	Adventure	Unknown	0.01	0.00	0.00	0.00	0.01
16427	16430	Virtua Quest	GC	NaN	Role- Playing	Unknown	0.01	0.00	0.00	0.00	0.01
16493	16496	The Smurfs	3DS	NaN	Action	Unknown	0.00	0.01	0.00	0.00	0.01

271 rows × 11 columns

```
In [114]: # фильтр по колонке
                                      data_num[data_num.index.isin(flt_index)]['Year']
  Out[114]: 179
                                                                NaN
                                                                 NaN
                                      431
                                                                NaN
                                      470
                                                                 NaN
                                      607
                                                                NaM
                                      16307
                                                                NaN
                                      16327
                                                                NaN
                                      16366
                                      16427
                                                                NaN
                                      16493
                                                                NaN
                                      Name: Year, Length: 271, dtype: float64
  In [115]: data_num_Year = data_num[['Year']]
    data_num_Year.head()
  Out[115]:
                                       0 2006.0
                                        1 1985.0
                                       2 2008.0
                                        3 2009.0
                                        4 1996.0
   In [116]: from sklearn.impute import SimpleImputer
                                      from sklearn.impute import MissingIndicator
  In [117]: # Фильтр для проверки заполнения пустых значений
                                     indicator = MissingIndicator()
                                      mask_missing_values_only = indicator.fit_transform(data_num_Year)
                                     mask_missing_values_only
  Out[117]: array([[False],
                                                            [False],
[False],
                                                              [False],
                                                               [False]
                                                             [False]])
  In [118]:
    strategies=['mean', 'median','most_frequent']
    def test_num_impute(strategy_param):
        imp_num = SimpleImputer(strategy=strategy_param)
                                                   data_num_imp = imp_num.fit_transform(data_num_Year)
                                                  return data_num_imp[mask_missing_values_only]
  In [119]: strategies[0], test_num_impute(strategies[0])
Out[119]: ('mean'
                                      array([2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                              2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                               2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                               2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                              2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                              2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                              2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                              2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
                                                               2006.40644331, 2006.40644331, 2006.40644331, 2006.40644331,
  In [120]: strategies[1], test_num_impute(strategies[1])
  Out[120]: ('median'
                                        array([2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 20
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 20
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                                2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007.,
                                                               2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 2007., 20
```

```
In [121]: strategies[2], test_num_impute(strategies[2])
Out[121]: ('most frequent',
                                          array([2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009.,
                                                                  2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 20
                                                                   2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009.,
                                                                   2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009.,
                                                                    2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009.,
                                                                  2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 20
                                                                   2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009.,
                                                                   2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009., 2009.,
   In [122]: # Более сложная функция, которая позволяет задавать колонку и вид импьютации
                                        def test_num_impute_col(dataset, column, strategy_param):
                                                     temp_data = dataset[[column]]
                                                     indicator = MissingIndicator()
                                                     mask_missing_values_only = indicator.fit_transform(temp_data)
                                                     imp_num = SimpleImputer(strategy=strategy_param)
data_num_imp = imp_num.fit_transform(temp_data)
                                                      filled_data = data_num_imp[mask_missing_values_only]
                                                     return column, strategy_param, filled_data.size, filled_data[0], filled_data[filled_data.size-1]
   In [123]: data[['Year']].describe()
   Out[123]:
                                          count 16327.000000
                                            mean 2006.406443
                                          std 5.828981
                                               min 1980.000000
                                             25% 2003.000000
                                            75% 2010.000000
                                               max 2020 000000
   In [124]: test_num_impute_col(data, 'Year', strategies[0])
Out[124]: ('Year', 'mean', 271, 2006.4064433147546, 2006.4064433147546)
In [125]: test_num_impute_col(data, 'Year', strategies[1])
Out[125]: ('Year', 'median', 271, 2007.0, 2007.0)
In [126]: test_num_impute_col(data, 'Year', strategies[2])
Out[126]: ('Year', 'most_frequent', 271, 2009.0, 2009.0)
```

## 2.2.2. Обработка пропусков в категориальных данных

#### Обработка пропусков в категориальных данных

```
In [127]: # Выберем категориальные колонки с пропущенными значениями # Цикл по колонкам датасета
            cat_cols = []
            for col in data.columns:
                 # Количество пустых значений temp_null_count = data[data[col].isnull()].shape[0]
                 dt = str(data[col].dtype)
if temp_null_count>0 and (dt=='object'):
                     cat_cols.append(col)
temp_perc = round((temp_null_count / total_count) * 100.0, 2)
                     print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col, dt, temp_null_count, temp_perc))
            Колонка Publisher. Тип данных object. Количество пустых значений 58, 0.35%.
In [128]: cat_temp_data = data[['Publisher']]
            cat_temp_data.head()
Out[128]:
               Publisher
             0 Nintendo
            2 Nintendo
             3 Nintendo
In [129]: cat_temp_data['Publisher'].unique()
```

```
In [130]: cat_temp_data[cat_temp_data['Publisher'].isnull()].shape
Out[130]: (58, 1)
In [131]: # Импьютация наиболее частыми значениями
         imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
         data_imp2 = imp2.fit_transform(cat_temp_data)
         data_imp2
Out[131]: array([['Nintendo'],
               ['Nintendo'],
               ['Activision'],
              ['7G//AMES'],
['Wanadoo']], dtype=object)
In [132]: # Пустые значения отсутствуют
        np.unique(data_imp2)
In [133]: # Импьютация константой
        imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='EA')
data_imp3 = imp3.fit_transform(cat_temp_data)
         data imp3
Out[133]: array([['Nintendo'],
               ['Nintendo'],
['Nintendo'],
               ['Activision'],
              ['7G//AMES'],
['Wanadoo']], dtype=object)
In [134]: np.unique(data_imp3)
```

```
In [135]: data_imp3[data_imp3=='EA'].size
Out[135]: 58
```

#### 3. Преобразование категориальных признаков в числовые

#### Преобразование категориальных признаков в числовые



# 3.1. Кодирование категорий целочисленными значениями – label encoding

#### Кодирование категорий целочисленными значениями - label encoding

```
In [139]: np.unique(cat_enc_le)
Out[139]: array([ 0,
                                                               30,
43,
                                                                       31,
44,
                                                                                32,
45,
                                                                                                34,
47,
                                                                                                        35,
48,
                               26,
                                      27,
                                             28,
                                                       29,
                                                                                        33,
                                                                                                                 36,
                                                       42,
                                                                                        46,
                                                                                                                 49,
                                      40,
                                              41,
                                                                                                                         50,
                               39,
                                                                                                                                 51,
                                                       55,
                                                               56,
                                                                       57,
                                                                                58,
                                                                                        59,
                                                                                                60,
                                                                                                        61,
                                      66, 67, 68, 69,
                                                                       70,
                                                                                71,
                               65,
                                                                                        72,
                                                                                                73,
                                                                                                        74,
                                                                                                                 75,
                                                                                                                         76,
                                             80, 81, 82,
                                                                                                        87,
                                                                       83,
                             91, 92, 93, 94, 95, 96, 97, 98, 99, 100, 101, 102, 103, 104, 105, 106, 107, 108, 109, 110, 111, 112, 113, 114, 115, 116,
                             117, 118, 119, 120, 121, 122, 123, 124, 125, 126, 127, 128, 129, 130, 131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 142,
                             143, 144, 145, 146, 147, 148, 149, 150, 151, 152, 153, 154, 155,
                             156, 157, 158, 159, 160, 161, 162, 163, 164, 165, 166, 167, 168, 169, 170, 171, 172, 173, 174, 175, 176, 177, 178, 179, 180, 181,
                             182, 183, 184, 185, 186, 187, 188, 189, 190, 191, 192, 193, 194, 195, 196, 197, 198, 199, 200, 201, 202, 203, 204, 205, 206, 207,
                             208, 209, 210, 211, 212, 213, 214, 215, 216, 217, 218, 219, 220,
                             221, 222, 223, 224, 225, 226, 227, 228, 229, 230, 231, 232, 233, 234, 235, 236, 237, 238, 239, 240, 241, 242, 243, 244, 245, 246,
                             247, 248, 249, 250, 251, 252, 253, 254, 255, 256, 257, 258, 259, 260, 261, 262, 263, 264, 265, 266, 267, 268, 269, 270, 271, 272,
                             273, 274, 275, 276, 277, 278, 279, 280, 281, 282, 283, 284, 285,
                             286, 287, 288, 289, 290, 291, 292, 293, 294, 295, 296, 297, 298, 299, 300, 301, 302, 303, 304, 305, 306, 307, 308, 309, 310, 311,
                             312, 313, 314, 315, 316, 317, 318, 319, 320, 321, 322, 323, 324, 325, 326, 327, 328, 329, 330, 331, 332, 333, 334, 335, 336, 337,
                             338, 339, 340, 341, 342, 343, 344, 345, 346, 347, 348, 349, 350, 351, 352, 353, 354, 355, 356, 357, 358, 359, 360, 361, 362, 363,
                              364, 365, 366, 367, 368, 369, 370, 371, 372, 373, 374, 375, 376,
                             377, 378, 379, 380, 381, 382, 383, 384, 385, 386, 387, 388, 389, 390, 391, 392, 393, 394, 395, 396, 397, 398, 399, 400, 401, 402,
                             403, 404, 405, 466, 407, 408, 409, 410, 411, 412, 413, 414, 415, 416. 417. 418. 419. 420. 421. 422. 423. 424. 425. 426. 427. 428. 429, 430, 431, 432, 433, 434, 435, 436, 437, 438, 439, 440, 441,
                             442, 443, 444, 445, 446, 447, 448, 449, 450, 451, 452, 453, 454, 455, 456, 457, 458, 459, 460, 461, 462, 463, 464, 465, 466, 467,
                             468, 469, 470, 471, 472, 473, 474, 475, 476, 477, 478, 479, 480, 481, 482, 483, 484, 485, 486, 487, 488, 489, 490, 491, 492, 493, 494, 495, 496, 497, 498, 499, 500, 501, 502, 503, 504, 505, 506,
                             507, 508, 509, 510, 511, 512, 513, 514, 515, 516, 517, 518, 519,
                              520, 521, 522, 523, 524, 525, 526, 527, 528, 529, 530, 531, 532,
                             533, 534, 535, 536, 537, 538, 539, 540, 541, 542, 543, 544, 545, 546, 547, 548, 549, 550, 551, 552, 553, 554, 555, 556, 557, 558,
                             559, 560, 561, 562, 563, 564, 565, 566, 567, 568, 569, 570, 571, 572, 573, 574, 575, 576, 577])
In [140]: le.inverse_transform([0, 1, 2, 3])
Out[140]: array(['10TACLE Studios', '1C Company', '20th Century Fox Video Games', '2D Boy'], dtype=object)
```

# 3.2. Кодирование категорий наборами бинарных значений – one-hot encoding

#### Кодирование категорий наборами бинарных значений - one-hot encoding

Out[146]:		c1
	0	Nintendo
	1	Nintendo
	2	Nintendo
	3	Nintendo
	4	Nintendo
	5	Nintendo
	6	Nintendo
	7	Nintendo
	8	Nintendo
	9	Nintendo

## 3.3. Pandas\_get\_dummies – быстрый вариант one-hot кодирования



# 4. Масштабирование данных

2000

# 4.1. МіпМах масштабирование

#### Масштабирование данных

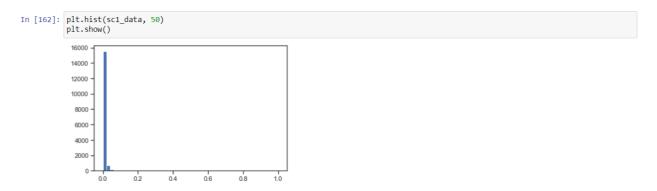
```
In [159]: from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer

MinMax масштабирование

In [160]: sc1 = MinMaxScaler() sc1_data = sc1.fit_transform(data[['Global_Sales']])

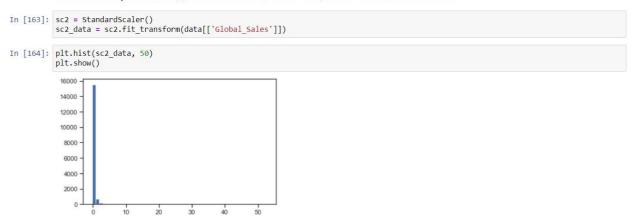
In [161]: plt.hist(data['Global_Sales'], 50) plt.show()

16000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 12000 - 1
```



## 4.2. Масштабирование данных на основе Z-оценки – StandardScaler

#### Масштабирование данных на основе Z-оценки - StandardScaler



#### 4.3. Нормализация данных

#### Нормализация данных

```
In [165]: sc3 = Normalizer()
sc3_data = sc3.fit_transform(data[['Global_Sales']])

In [166]: plt.hist(sc3_data, 50)
plt.show()

16000
12000
10000
8000
4000
2000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
10000
1
```